

WOJSKOWA AKADEMIA TECHNICZNA

im. Jarosława Dąbrowskiego

WYDZIAŁ CYBERNETYKI



Sprawozdanie

Zaawansowane metody uczenia maszynowego

Sieci Neuronowe – pojedyncza warstwa ukryta

Autor:

Karol Baranowski

Prowadzący:

mgr inż. Przemysław Czuba

Spis treści

Zadanie.....	3
Wstęp.....	4
Porównanie wyników.....	4
relu – relu.....	5
relu – sigmoid.....	6
relu – tanh.....	7
sigmoid – relu.....	8
sigmoid – sigmoid.....	9
sigmoid – tanh.....	10
tanh – relu.....	11
tanh – sigmoid.....	12
tanh – tanh.....	13
Wnioski końcowe.....	14

Zadanie

Dla zbioru danych użytego w przykładzie PlanarClassification zaimplementować sieć neuronową przy użyciu framework'a PyTorch.

- Zaimplementować strukturę analogiczną jak w przykładzie
- Wykonać porównania wyników oraz czasów uczenia dla:
 - Różnej liczby neuronów w warstwie ukrytej
 - Różnych funkcji aktywacji (sigmoid, tanh, ReLU)•
- (dla chętnych) Użyć innego zbioru danych do klasyfikacji binarnej

Wstęp

Sieć ma za zadanie na podstawie dwóch wartości punktu, rozpoznawać jego kolor wykorzystując klasyfikację binarną. Zadanie zrealizowano używając frameworka PyTorch. Jako dane do trenowania sieci przyjęto zbiór danych z przykładu *PlanarClassification*. Następnie wygenerowano losowe dane testowe o wielkości 20% danych treningowych z tego samego przykładu ale używając innego żarna.

Porównanie wyników

Porównano działanie trzech funkcji aktywacji (sigmoid, tanh, ReLU) na dwóch warstwach – ukrytej i wyjściowej, łącznie dziewięć testów. Dla każdego testu sieć trenowano oddzielnie używając 1, 2 ,3 ,4 ,5, 10, 20 i 50 neuronów w warstwie ukrytej analogicznie jak w załączonym do zadania przykładzie *neural_net.py*.

Poniżej wyniki testów i omówienie najważniejszych obserwacji:

relu – relu

Activation function on hidden layer: relu

Activation function on output layer: relu

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.28543
Cost after 100 epochs:	0.24977
Cost after 10000 epochs:	0.22532
Time of training:	3.0519 s
Accuracy:	61.25%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.62500
Cost after 100 epochs:	0.32042
Cost after 10000 epochs:	0.20820
Time of training:	3.1494 s
Accuracy:	73.75%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.75227
Cost after 100 epochs:	0.32131
Cost after 10000 epochs:	0.22126
Time of training:	3.4574 s
Accuracy:	56.25%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.42156
Cost after 100 epochs:	0.27822
Cost after 10000 epochs:	0.15798
Time of training:	3.8837 s
Accuracy:	80.00%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.48032
Cost after 100 epochs:	0.42505
Cost after 10000 epochs:	0.17748
Time of training:	4.3402 s
Accuracy:	73.75%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.49727
Cost after 100 epochs:	0.38698
Cost after 10000 epochs:	0.09975
Time of training:	4.1027 s
Accuracy:	81.25%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.38687
Cost after 100 epochs:	0.26678
Cost after 10000 epochs:	0.09123
Time of training:	5.4077 s
Accuracy:	82.50%

Zastosowanie ReLu na warstwie ukrytej i wyjścia dało wysoki wynik już od użycia 4 neuronów w ukrytej warstwie. ReLu szybko radzi sobie z ujemnymi wartościami ponieważ przybliża je do 0. Wyliczony koszt dla 20 i 50 neuronów jest najniższy ze wszystkich testów. Zazwyczaj ReLu używa się do warstw ukrytych, gdyż przyspiesza uczenie.

relu – sigmoid

Activation function on hidden layer: relu

Activation function on output layer: sigmoid

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.30098
Cost after 100 epochs:	0.29255
Cost after 10000 epochs:	0.23116
Time of training:	3.0823 s
Accuracy:	55.00%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.27002
Cost after 100 epochs:	0.26605
Cost after 10000 epochs:	0.22370
Time of training:	3.6828 s
Accuracy:	61.25%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.27691
Cost after 100 epochs:	0.26993
Cost after 10000 epochs:	0.22483
Time of training:	3.7037 s
Accuracy:	68.75%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.26461
Cost after 100 epochs:	0.26000
Cost after 10000 epochs:	0.22453
Time of training:	3.7004 s
Accuracy:	61.25%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.25001
Cost after 100 epochs:	0.24693
Cost after 10000 epochs:	0.22425
Time of training:	3.5939 s
Accuracy:	60.00%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.26559
Cost after 100 epochs:	0.24736
Cost after 10000 epochs:	0.17268
Time of training:	4.0321 s
Accuracy:	78.75%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.26375
Cost after 100 epochs:	0.24236
Cost after 10000 epochs:	0.13219
Time of training:	5.0175 s
Accuracy:	81.25%

Kombinacja ta daje wysoką dokładność dla wyższej ilości neuronów w ukrytej warstwie (20). Poza tym od początku wartość kosztu jest stosunkowo niska. Sigmoid nadaje się na funkcję aktywacji warstwy wychodzącej w klasyfikacji binarnej, ponieważ zwraca wynik z przedziału 0 i 1.

relu – tanh

Activation function on hidden layer: relu

Activation function on output layer: tanh

Neurons in hidden layer: 1	
Cost after 1 epoch:	1.80961
Cost after 100 epochs:	0.30273
Cost after 10000 epochs:	0.24056
Time of training:	3.3342 s
Accuracy:	45.00%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.27044
Cost after 100 epochs:	0.24869
Cost after 10000 epochs:	0.23389
Time of training:	3.7985 s
Accuracy:	60.00%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.26884
Cost after 100 epochs:	0.25368
Cost after 10000 epochs:	0.23545
Time of training:	3.8444 s
Accuracy:	60.00%
Neurons in hidden layer: 4	
Cost after 1 epoch:	1.44692
Cost after 100 epochs:	0.25101
Cost after 10000 epochs:	0.21551
Time of training:	3.7728 s
Accuracy:	60.00%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.95975
Cost after 100 epochs:	0.24084
Cost after 10000 epochs:	0.19796
Time of training:	3.8918 s
Accuracy:	71.25%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.33156
Cost after 100 epochs:	0.24742
Cost after 10000 epochs:	0.10714
Time of training:	4.2331 s
Accuracy:	80.00%
Neurons in hidden layer: 50	
Cost after 1 epoch:	1.13878
Cost after 100 epochs:	0.23076
Cost after 10000 epochs:	0.10011
Time of training:	6.5994 s
Accuracy:	82.50%

Wyniki podobne jak dla relu-sigmoid, dokładność 80% od 20 neuronów w ukrytej warstwie. Nieco dokładniejsza (~1,5%) dla 50 neuronów ale o 1,5 s wolniejsza.

sigmoid – relu

Activation function on hidden layer: sigmoid

Activation function on output layer: relu

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.50000
Cost after 100 epochs:	0.50000
Cost after 10000 epochs:	0.50000
Time of training:	4.7129 s
Accuracy:	50.00%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.50000
Cost after 100 epochs:	0.50000
Cost after 10000 epochs:	0.50000
Time of training:	4.2647 s
Accuracy:	50.00%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.24799
Cost after 100 epochs:	0.24264
Cost after 10000 epochs:	0.16270
Time of training:	4.0560 s
Accuracy:	80.00%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.39298
Cost after 100 epochs:	0.26711
Cost after 10000 epochs:	0.17389
Time of training:	4.1152 s
Accuracy:	81.25%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.47828
Cost after 100 epochs:	0.25875
Cost after 10000 epochs:	0.15296
Time of training:	4.0819 s
Accuracy:	81.25%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.34981
Cost after 100 epochs:	0.24783
Cost after 10000 epochs:	0.13659
Time of training:	4.5248 s
Accuracy:	78.75%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.30819
Cost after 100 epochs:	0.23316
Cost after 10000 epochs:	0.13948
Time of training:	5.6148 s
Accuracy:	78.75%

Czas rośnie stosunkowo wolno wraz z wzrostem ilości neuronów. Od 3 neuronów dokładność wysoka (80%), jednak dokładność nie rośnie wraz z wzrostem ilości neuronów, a wręcz minimalnie opada.

sigmoid – sigmoid

Activation function on hidden layer: sigmoid

Activation function on output layer: sigmoid

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.26827
Cost after 100 epochs:	0.26459
Cost after 10000 epochs:	0.24126
Time of training:	3.4010 s
Accuracy:	63.75%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.27893
Cost after 100 epochs:	0.27083
Cost after 10000 epochs:	0.23958
Time of training:	4.0056 s
Accuracy:	60.00%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.26151
Cost after 100 epochs:	0.25607
Cost after 10000 epochs:	0.22790
Time of training:	4.0192 s
Accuracy:	45.00%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.25020
Cost after 100 epochs:	0.24935
Cost after 10000 epochs:	0.23215
Time of training:	4.0137 s
Accuracy:	58.75%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.25664
Cost after 100 epochs:	0.25568
Cost after 10000 epochs:	0.23799
Time of training:	3.9989 s
Accuracy:	63.75%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.27403
Cost after 100 epochs:	0.25790
Cost after 10000 epochs:	0.22744
Time of training:	4.3436 s
Accuracy:	55.00%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.27130
Cost after 100 epochs:	0.25053
Cost after 10000 epochs:	0.21126
Time of training:	5.3340 s
Accuracy:	63.75%

Niska dokładność (60%) prawie dla każdej ilości neuronów, w szczególności dla 3 (45%).

sigmoid – tanh

Activation function on hidden layer: sigmoid

Activation function on output layer: tanh

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.69554
Cost after 100 epochs:	0.32161
Cost after 10000 epochs:	0.24121
Time of training:	3.5595 s
Accuracy:	50.00%
Neurons in hidden layer: 2	
Cost after 1 epoch:	1.17165
Cost after 100 epochs:	0.27461
Cost after 10000 epochs:	0.22273
Time of training:	3.9825 s
Accuracy:	51.25%
Neurons in hidden layer: 3	
Cost after 1 epoch:	1.38313
Cost after 100 epochs:	0.24022
Cost after 10000 epochs:	0.15483
Time of training:	3.9777 s
Accuracy:	80.00%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.26924
Cost after 100 epochs:	0.26173
Cost after 10000 epochs:	0.20595
Time of training:	4.1236 s
Accuracy:	71.25%
Neurons in hidden layer: 5	
Cost after 1 epoch:	1.41704
Cost after 100 epochs:	0.25335
Cost after 10000 epochs:	0.22162
Time of training:	4.0989 s
Accuracy:	51.25%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.28840
Cost after 100 epochs:	0.23745
Cost after 10000 epochs:	0.14029
Time of training:	4.5608 s
Accuracy:	81.25%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.71697
Cost after 100 epochs:	0.24373
Cost after 10000 epochs:	0.14341
Time of training:	5.8971 s
Accuracy:	82.50%

Wysoka dokładność dla wielu neuronów (20, 50). Dla małych ilości neuronów dokładność waha się co przedstawiono powyżej w wyniku dla 2,3 i 4 neuronów.

tanh – relu

Activation function on hidden layer: tanh

Activation function on output layer: relu

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.25041
Cost after 100 epochs:	0.24952
Cost after 10000 epochs:	0.24108
Time of training:	3.6662 s
Accuracy:	46.25%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.23174
Cost after 100 epochs:	0.22376
Cost after 10000 epochs:	0.21012
Time of training:	4.3327 s
Accuracy:	52.50%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.44088
Cost after 100 epochs:	0.24948
Cost after 10000 epochs:	0.11674
Time of training:	4.1510 s
Accuracy:	82.50%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.38939
Cost after 100 epochs:	0.32725
Cost after 10000 epochs:	0.11635
Time of training:	4.2101 s
Accuracy:	82.50%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.39877
Cost after 100 epochs:	0.23982
Cost after 10000 epochs:	0.11683
Time of training:	4.1998 s
Accuracy:	83.75%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.43459
Cost after 100 epochs:	0.27959
Cost after 10000 epochs:	0.10718
Time of training:	4.8268 s
Accuracy:	80.00%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.48854
Cost after 100 epochs:	0.27838
Cost after 10000 epochs:	0.10381
Time of training:	19.8721 s
Accuracy:	81.25%

Długi czas liczenia dla wielu neuronów. Tanh stosuje się raczej jako warstwę wychodzącą. Dokładność wysoka od 3 neuronów.

tanh – sigmoid

Activation function on hidden layer: tanh

Activation function on output layer: sigmoid

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.25771
Cost after 100 epochs:	0.25330
Cost after 10000 epochs:	0.22753
Time of training:	3.5404 s
Accuracy:	63.75%
Neurons in hidden layer: 2	
Cost after 1 epoch:	0.25187
Cost after 100 epochs:	0.24828
Cost after 10000 epochs:	0.21121
Time of training:	4.0607 s
Accuracy:	55.00%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.26222
Cost after 100 epochs:	0.25584
Cost after 10000 epochs:	0.18534
Time of training:	4.1268 s
Accuracy:	77.50%
Neurons in hidden layer: 4	
Cost after 1 epoch:	0.29588
Cost after 100 epochs:	0.28382
Cost after 10000 epochs:	0.13124
Time of training:	4.1392 s
Accuracy:	81.25%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.24380
Cost after 100 epochs:	0.24154
Cost after 10000 epochs:	0.13103
Time of training:	4.3492 s
Accuracy:	82.50%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.27276
Cost after 100 epochs:	0.25430
Cost after 10000 epochs:	0.12389
Time of training:	4.7602 s
Accuracy:	83.75%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.24877
Cost after 100 epochs:	0.22872
Cost after 10000 epochs:	0.12230
Time of training:	19.3468 s
Accuracy:	83.75%

Wysoka dokładność od 3 neuronów. Wyniki podobne do tanh-ReLu, chociaż dokładność wyższa dla warstw z 1 i 2 neuronami.

tanh – tanh

Activation function on hidden layer: tanh

Activation function on output layer: tanh

Neurons in hidden layer: 1	
Cost after 1 epoch:	0.37425
Cost after 100 epochs:	0.25801
Cost after 10000 epochs:	0.23001
Time of training:	3.5484 s
Accuracy:	63.75%
Neurons in hidden layer: 2	
Cost after 1 epoch:	1.47935
Cost after 100 epochs:	0.26894
Cost after 10000 epochs:	0.21498
Time of training:	3.9742 s
Accuracy:	67.50%
Neurons in hidden layer: 3	
Cost after 1 epoch:	0.40129
Cost after 100 epochs:	0.24914
Cost after 10000 epochs:	0.11678
Time of training:	4.1621 s
Accuracy:	83.75%
Neurons in hidden layer: 4	
Cost after 1 epoch:	1.16323
Cost after 100 epochs:	0.32405
Cost after 10000 epochs:	0.11731
Time of training:	4.0378 s
Accuracy:	83.75%
Neurons in hidden layer: 5	
Cost after 1 epoch:	0.94110
Cost after 100 epochs:	0.24054
Cost after 10000 epochs:	0.11931
Time of training:	4.2478 s
Accuracy:	85.00%
Neurons in hidden layer: 20	
Cost after 1 epoch:	0.76288
Cost after 100 epochs:	0.23236
Cost after 10000 epochs:	0.11486
Time of training:	4.7701 s
Accuracy:	85.00%
Neurons in hidden layer: 50	
Cost after 1 epoch:	0.70679
Cost after 100 epochs:	0.22155
Cost after 10000 epochs:	0.11600
Time of training:	23.9537 s
Accuracy:	83.75%

Najwyższa dokładność z przeprowadzonych testów. Wyniki najwyższe dla warstw z 5 i 20 neuronami. Dla 50 spada o 1,25% i 4-krotnie wydłuża czas. Dla warstw z 1 lub 2 neuronami wynik dość niski.

Wnioski końcowe

- Cel zadania został osiągnięty. Sieć, w zależności od dobranych parametrów i funkcji aktywacji, uczyła się (minimalizowała funkcję kosztu) wykorzystując dane treningowe, a następnie była w stanie zwrócić poprawnie (najlepiej w 85%) wyniki dla danych testowych, których wcześniej nie analizowała.
- Oprócz ilości warstw oraz użytych funkcji aktywacji, duże znaczenie ma dobranie algorytmu optymalizacji i normalizacji. W zadaniu użyto do estymacji błędu średniokwadratowego (MSE), a do optymalizacji stochastycznego spadku gradientu (SGD). Warto dodać, że wyniki z wysoką poprawnością dla funkcji aktywacji sigmoid uzyskano również używając do normalizacji Binary Cross Entropy (BCELoss), który mierzy entropię pomiędzy elementami warstwy wejścia, a wyjścia. Jednak jest to algorytm stworzony typowo do klasyfikacji binarnej i działa tylko dla wartości z pomiędzy 0 i 1 więc dla danych znormalizowanych funkcją sigmoid. Nie można było tej funkcji zastosować dla danych z tanh i ReLu.
- Średnio czas uczenia dla 10000 iteracji zbioru 800 elementowego z zadania trwał na sprzęcie autora około 5 sekund dla funkcji sigmoid i ReLu na warstwie ukrytej. Czas uczenia, gdy w tej warstwie użyty był tanh był 4 razy dłuższy dla 50 neuronów w warstwie ukrytej.
- Im więcej neuronów w ukrytej warstwie tym dłuższy czas uczenia i w zależności od funkcji aktywacji – wynik lepszy bądź od pewnej ilości neuronów nie poprawia się, a nawet maleje.
- Learning rate ustawiono na 0,01 – zaobserwowano, że dla takiego parametru dokładność predykcji była najwyższa.
- Czas uczenia można by przyspieszyć używając mocniejszego sprzętu z wieloma kartami graficznymi, gdyż dostępna jest wersja pytorch-cuda wspierająca równoległe obliczenia na wielu kartach.